

AI模型性能测试报告

生成时间: 2025年12月30日 17:55:54

报告编号: 20251230175554

多模型性能对比

模型	TTFT P90 (ms)	Token吞吐	成功率	延迟最大值	延迟P99	延迟最小值
deepseek	1960.91	18.50	100.00%	3529.51	3523.47	2924.70
kimi	1243.84	174.84	100.00%	1346.57	1345.22	1210.87

模型 1 - deepseek

测试概览

总测试次数	2
成功次数	2
失败次数	0
错误率	0.00%

延迟性能指标 (ms)

平均值	3227.10
P90	3469.03
P99	3523.47
最小值	2924.70
最大值	3529.51

TTFT指标 (ms)

平均值	1951.34
P90	1960.91
P99	1963.06
最小值	1939.38
最大值	1963.30

Token吞吐指标 (tokens/s)

平均值	18.50
P90	20.41
P99	20.83
最小值	16.12
最大值	20.88

总Token数指标

平均值	37.50
P90	45.90

P99	47.79
最小值	27.00
最大值	48.00

模型 2 - kimi

测试概览

总测试次数	2
成功次数	2
失败次数	0
错误率	0.00%

延迟性能指标 (ms)

平均值	1278.72
P90	1333.00
P99	1345.22
最小值	1210.87
最大值	1346.57

TTFT指标 (ms)

平均值	1197.65
P90	1243.84
P99	1254.24
最小值	1139.91
最大值	1255.39

Token吞吐指标 (tokens/s)

平均值	174.84
P90	192.20
P99	196.11
最小值	153.14
最大值	196.54

总Token数指标

平均值	14.00
P90	14.00

P99	14.00
最小值	14.00
最大值	14.00

报告说明

本报告由AI模型性能拨测系统自动生成。

指标说明：

- TTFT (Time to First Token): 从发送请求到收到第一个token的时间
- Token吞吐: 每秒生成的token数量
- 延迟: 从发送请求到收到完整响应的时间
- P90/P99: 90%/99%的请求延迟低于此值